



Année 2024–2025

MASTER 2 Professionnel

Spécialité : **Ingénierie Mathématique**

Rapport de Stage

**Segmentation perceptuelle d'images :
combiner modèles probabilistes et méthodes d'apprentissage**

Étudiant	Kuassi Pierre Dovodji
Référente à l'université	Claire Launay, Maîtresse de conférences
Candidate	Jacques Froment, Professeur des universités
Date de la soutenance	27/08/2025

Plan

- 1 Introduction
- 2 Segmentation d'image
- 3 Articles
- 4 Travaux personnels
- 5 Discussion et conclusion

Contexte et problématique

Contexte

La segmentation d'images est essentielle en vision par ordinateur (médical, conduite autonome, industrie).

Problématique

Comment allier **modèles probabilistes** et **méthodes modernes** pour une segmentation perceptuelle **efficace**, **robuste** et **compétitive** ?

Objectifs

- Étudier FlexMM (mélanges régularisés, EM) et SAM (Vision Transformer + SA-1B).
- Comparer leurs performances sur des jeux de données variés.
- Proposer une amélioration hybride tirant parti des deux approches.

Plan

- 1 Introduction
- 2 Segmentation d'image
- 3 Articles
- 4 Travaux personnels
- 5 Discussion et conclusion


Définition et objectifs

Définition

Découper une image en régions homogènes et pertinentes (objets, structures, textures).

Objectifs

- **Simplifier** l'analyse et la prise de décision.
- **Localiser** les objets (masques précis).
- **Améliorer** la robustesse des pipelines (ex. détection → suivi).



Exemples



(a) Source Image



(b) Semantic Segmentation



(c) Instance Segmentation

Figure 1 : Différents types de segmentation d'images

Méthodes

Régions non texturées (SRNT)

- + Simple, rapide
- Peu robuste aux textures

Seuillage / clustering (Otsu, k -means, GMM)

- + Automatique, peu coûteux
- Sensible au bruit, choix du seuil

Basée contours (Canny, active contours)

- + Efficace pour objets bien définis
- Mauvais en zones floues ou bruitées

Réseaux d'apprentissage (U-Net, DeepLab, ViT, SAM)

- + Très performants, généralisables
 - Coûteux en données et calculs
-

Métriques d'évaluation

Métrique	Formule	Interprétation
Précision	$\frac{TP}{TP + FP}$	Fiabilité des prédictions positives.
Rappel	$\frac{TP}{TP + FN}$	Capacité à retrouver tous les vrais positifs.
F1-score	$F_1 = \frac{2 \times \text{Précision} \times \text{Rappel}}{\text{Précision} + \text{Rappel}}$	Compromis entre précision et rappel.
ARI	$\frac{TP + TN}{TP + FP + FN + TN}$	Indice global de similarité (accords positifs et négatifs).

TP = vrais positifs, FP = faux positifs, FN = faux négatifs, TN = vrais négatifs

Plan

- 1 Introduction
- 2 Segmentation d'image
- 3 Articles
- 4 Travaux personnels
- 5 Discussion et conclusion

Idée générale

Modèle de **mélanges probabilistes flexiblement régularisés** :

- Modéliser chaque pixel x comme provenant d'un **mélange de K lois**(GNN ou Student-t) :

$$P_{X|P,A}(x|\mathbf{p}, \mathbf{a}) = \sum_{k=1}^K p_k P_{X^{(k)}}(x; a_k)$$

Chaque composante k correspond à une **région/classe** de l'image.

- Les probabilités de mélange sont **régularisées** en tenant compte de la **topologie des données** (ex. proximité spatiale des pixels).
- Les paramètres $(\mathbf{p}, \mathbf{a})$ sont estimés par maximisation de la vraisemblance via l'algorithme EM

Algorithme EM

Initialisation

Choix d'un point de départ pour les paramètres.

Étape E (Expectation)

On calcule l'espérance de la log-vraisemblance complète, conditionnellement aux données observées et aux paramètres estimés à l'itération précédente :

$$Q(\theta, \theta^{(t)}) = \mathbb{E}_{C_n | (X_n)_n, \theta} \left[\ell(p, a; (x_n, C_n)_n) \mid (x_n)_n, \theta^{(t)} \right].$$

Étape M (Maximization)

On met à jour les paramètres en maximisant l'espérance calculée précédemment :

$$\theta^{(t+1)} = \arg \max_{\theta} Q(\theta, \theta^{(t)}).$$

Modèle de mélange régularisé

Idée générale

- Modèle de mélange classique.
- On ajoute une **régularisation spatiale** : les probabilités de mélange dépendent aussi des voisins (Markov random field).
- Cela permet de **propager l'information locale** et de favoriser la cohérence des classes dans l'image.

Propriété de mise à jour

Pour chaque pixel n et chaque classe k :

$$p_{n,k}^{(t+1)} = \frac{u_{n,k} \left(\tau_{\cdot,k}^{(t)} \right)}{\sum_{k'=1}^K u_{n,k'} \left(\tau_{\cdot,k'}^{(t)} \right)},$$

où $\tau_{n,k}^{(t)}$ est la probabilité a posteriori calculée à l'étape E.

Combinaison de modèles de mélange

Idée générale

- Chaque échantillon est représenté par plusieurs vecteurs $x_n^{(h)}$ (multi-vues, ex. différentes couches d'un réseau).
- Chaque vue est modélisée par un **mélange de distributions** avec ses propres paramètres.
- Une **régularisation conjointe** des poids $p_{n,k}^{(h)}$ permet de partager l'information de classe entre les vues et de maintenir la cohérence.

Propriété de mise à jour


Pour chaque pixel n , classe k , et vue h :

$$p_{n,k}^{(t+1,h)} = \frac{u_{n,k}^{(h)}(\tau_{\cdot,k}^{(t,1)}, \dots, \tau_{\cdot,k}^{(t,H)})}{\sum_{k'=1}^K u_{n,k'}^{(h)}(\tau_{\cdot,k'}^{(t,1)}, \dots, \tau_{\cdot,k'}^{(t,H)})},$$

où $\tau_{n,k}^{(t,h)}$ est la probabilité a posteriori pour la vue h calculée à l'étape E.

Convergence de l'algorithme EM (FlexMM)

- La log-vraisemblance augmente de façon monotone à chaque itération.
- Convergence observée en ~ 15 itérations.



Exemple : Évolution de la log-vraisemblance au cours des itérations.


Forces

- **Flexibilité** : peut s'appliquer à différentes topologies (images, séquences, graphes).
- **Interprétable** : fournit une mesure probabiliste + incertitude des segmentations.
- **Robuste** : meilleure segmentation si distribution Student-t (résistant aux outliers).
- **Peu coûteux** : calcul linéaire et régularisation contrôlable.

Limites

- **Sensible à l'initialisation** et au choix du nombre de composantes K .
- Résultats inférieurs à l'humain.

Résultats illustratifs







Exemple : Segmentation d'image naturelle par FlexMM avec $K = 5$.



Vérité terrain.

Résultats illustratifs



Exemple : Carte de probabilité cas 5 classes.

Article 2 — Segment Anything (SAM)

Idée principale

Un modèle de **segmentation universelle** capable de générer des masques d'objets à partir de simples **prompts** (points, boîtes, texte).

Caractéristiques

- **Backbone** : Vision Transformer (ViT) pré-entraîné à grande échelle.
- **Données** : SA-1B, plus d'**1 milliard de masques annotés**.
- **Interaction** : prédictions rapides *sans ré-entraînement par image*.

Limites

- Performances variables sur **domaines spécialisés** (ex. médical).
- Sursegmentation.
- **Coût élevé** en mémoire et latence pour les grands modèles.

SAM — Schéma d'architecture




Figure 2 : Architecture générale du modèle SAM.

Application de SAM — Exemple



Exemple : segmentation d'image naturelle par SAM.

Plan

- 1 Introduction
- 2 Segmentation d'image
- 3 Articles
- 4 Travaux personnels**
- 5 Discussion et conclusion

Méthodes testées

- **Aléatoire** : sensible, segmentation dégradée.
- **K-means / DBSCAN** : résultats stables, convergence similaire.
- **Supervisé** (KNN, SVM, XGBoost) : peu d'impact, mais temps doublé.
- **SAM** : convergence plus rapide, résultats comparables.

Conclusion

Méthode peu sensible à l'initialisation, sauf en cas d'aléatoire pur. $\Rightarrow$ privilégier les approches simples et logiques (K-means, DBSCAN).

Étude de l'initialisation — Comparaison visuelle



K-means




DBSCAN



KNN



Aléatoire



SAM

Pipeline 1 : FlexMM $\rightarrow$ SAM


- FlexMM génère des *prompts* (classes, centroïdes).
- SAM affine ensuite les masques.
- Résultat : plus de classes détectées, mais F-Score en baisse malgré ARI élevé.



(a) Image originale



(b) SAM



(c) FlexMM+SAM

Méthode	Nb classes	F-Score	ARI
SAM	19	0.52	0.95
FlexMM+SAM	39	0.14	0.87

Pipeline 2 : SAM $\rightarrow$ FlexMM

- SAM génère d'abord des masques multiples.
- FlexMM régularise localement.
- Résultat : métriques élevées mais visuellement bruité (recouvrements).



Figure 3 : SAM+FlexMM (3 classes)




Figure 4 : FlexMM seul (3 classes)

Nb Classes	F-Score	ARI
3	0.40	0.92
6	0.47	0.92
9	0.42	0.95

Nb Classes	F-Score	ARI
3	0.40	0.91
6	0.34	0.91
9	0.12	0.89

Comparaison : SAM+FlexMM (gauche) vs FlexMM (droite)

Pipeline 3 : Encodage d'image $\rightarrow$ FlexMM

- Extraire les **features** via l'encodeur de SAM.
- Appliquer FlexMM dans l'espace latent.
- Problème : taille réduite de l'embedding $\Rightarrow$ sur-segmentation.



Image originale



Résultat sur-segmenté

$\Rightarrow$ Piste : **développer un encodeur à résolution équivalente pour limiter le suréchantillonnage.**

Comparaison des pipelines (métriques)

Méthode	Nb classes	F-Score	ARI
SAM (réf.)	19	0.52	0.95
FlexMM → SAM	39	0.14	0.87
SAM → FlexMM (3 classes)	3	0.40	0.92
SAM → FlexMM (6 classes)	6	0.47	0.92
SAM → FlexMM (9 classes)	9	0.42	0.95
Encodage image → FlexMM	–	–	–

Contexte des résultats

- **Nombre d'images testées** : Une quinzaine
- **Extrêmes** : résultats représentatifs, parmi les plus fréquents observés.

Nouvelle métrique : Entropie


Idée

Exploiter les **cartes de probabilité** de FlexMM via l'**entropie** pour mesurer l'incertitude de segmentation.

- Entropie par pixel :


$$h_{ij} = - \sum_{k=1}^K p_{ij}(k) \log p_{ij}(k)$$

- L'entropie **diminue au fil des itérations**, signe de convergence.



Évolution de l'entropie moyenne

Nouvelle métrique : Entropie



Cartes d'entropie (contours visibles)

Interprétation :

- ▷ Faible entropie $\Rightarrow$ segmentation sûre.
- ▷ Forte entropie $\Rightarrow$ incertitude (contours, zones complexes).

Conclusion

L'entropie est un bon **indicateur perceptuel** : elle reflète l'incertitude du modèle et met en évidence la qualité des frontières.



Vérité terrain.

Plan

- 1 Introduction
- 2 Segmentation d'image
- 3 Articles
- 4 Travaux personnels
- 5 Discussion et conclusion

Discussion

- Les combinaisons FlexMM–SAM donnent des résultats **hétérogènes** : $\Rightarrow$ bonnes métriques mais parfois incohérences visuelles.
- Les métriques classiques (F1, ARI) ne reflètent pas toujours la **qualité perceptuelle**.
- L'entropie apparaît comme un **indicateur complémentaire** pertinent.

Suggestions / Perspectives

- Optimiser les **prompts** de SAM (automatisation).
- Affiner FlexMM avec des **régularisations adaptatives**.
- Développer une **métrique perceptuelle** validée par des tests utilisateurs.

- Étude comparative de **FlexMM** et **SAM** sur la segmentation d'images.
- Proposition et test de **pipelines hybrides** : gains partiels mais limites identifiées.
- Mise en avant de l'**entropie** comme nouvelle piste pour l'évaluation perceptuelle.

Merci de votre attention !